

Санкт-Петербургский государственный университет

# Локальное масштабирование распределённых графовых алгоритмов в Galois

Руднев-Степанян Данила
23.Б11-мм

# Постановка задачи

- Вопрос: как для заданных алгоритма и графа меняется время обработки при увеличении числа MPI-процессов?
- Алгоритмы: BFS, SSSP, PageRank и подсчёт треугольников (TC).

# Экспериментальный стенд

- Intel Core i7-11800H: 8 ядер, 16 логических CPU, 16 ГБ RAM.
- Ubuntu 26.04.1 LTS, ядро Linux 7.0.0-38-generic.
- Open MPI 5.0.10.
- Galois b67f942, GCC 15.2.0, Release, -O3, -march=native.

# Наборы данных

| Граф | Вершины | Рёбра | Средняя степень | Характер графа |
|---|---|---|---|---|
| Citeseer | 227 320 | 814 134 | 7,16 | Соавторство |
| Belgium | 1 441 295 | 1 549 970 | 2,15 | Дорожный |
| Amazon | 735 323 | 3 523 472 | 9,58 | Совместные покупки |
| DBLP | 540 486 | 15 245 729 | 56,41 | Соавторство |
| RGG | 4 194 304 | 30 359 198 | 14,48 | Геометрический |
| LiveJournal | 4 847 571 | 42 851 237 | 17,68 | Социальный |

# Постановка эксперимента

## Реализации Galois

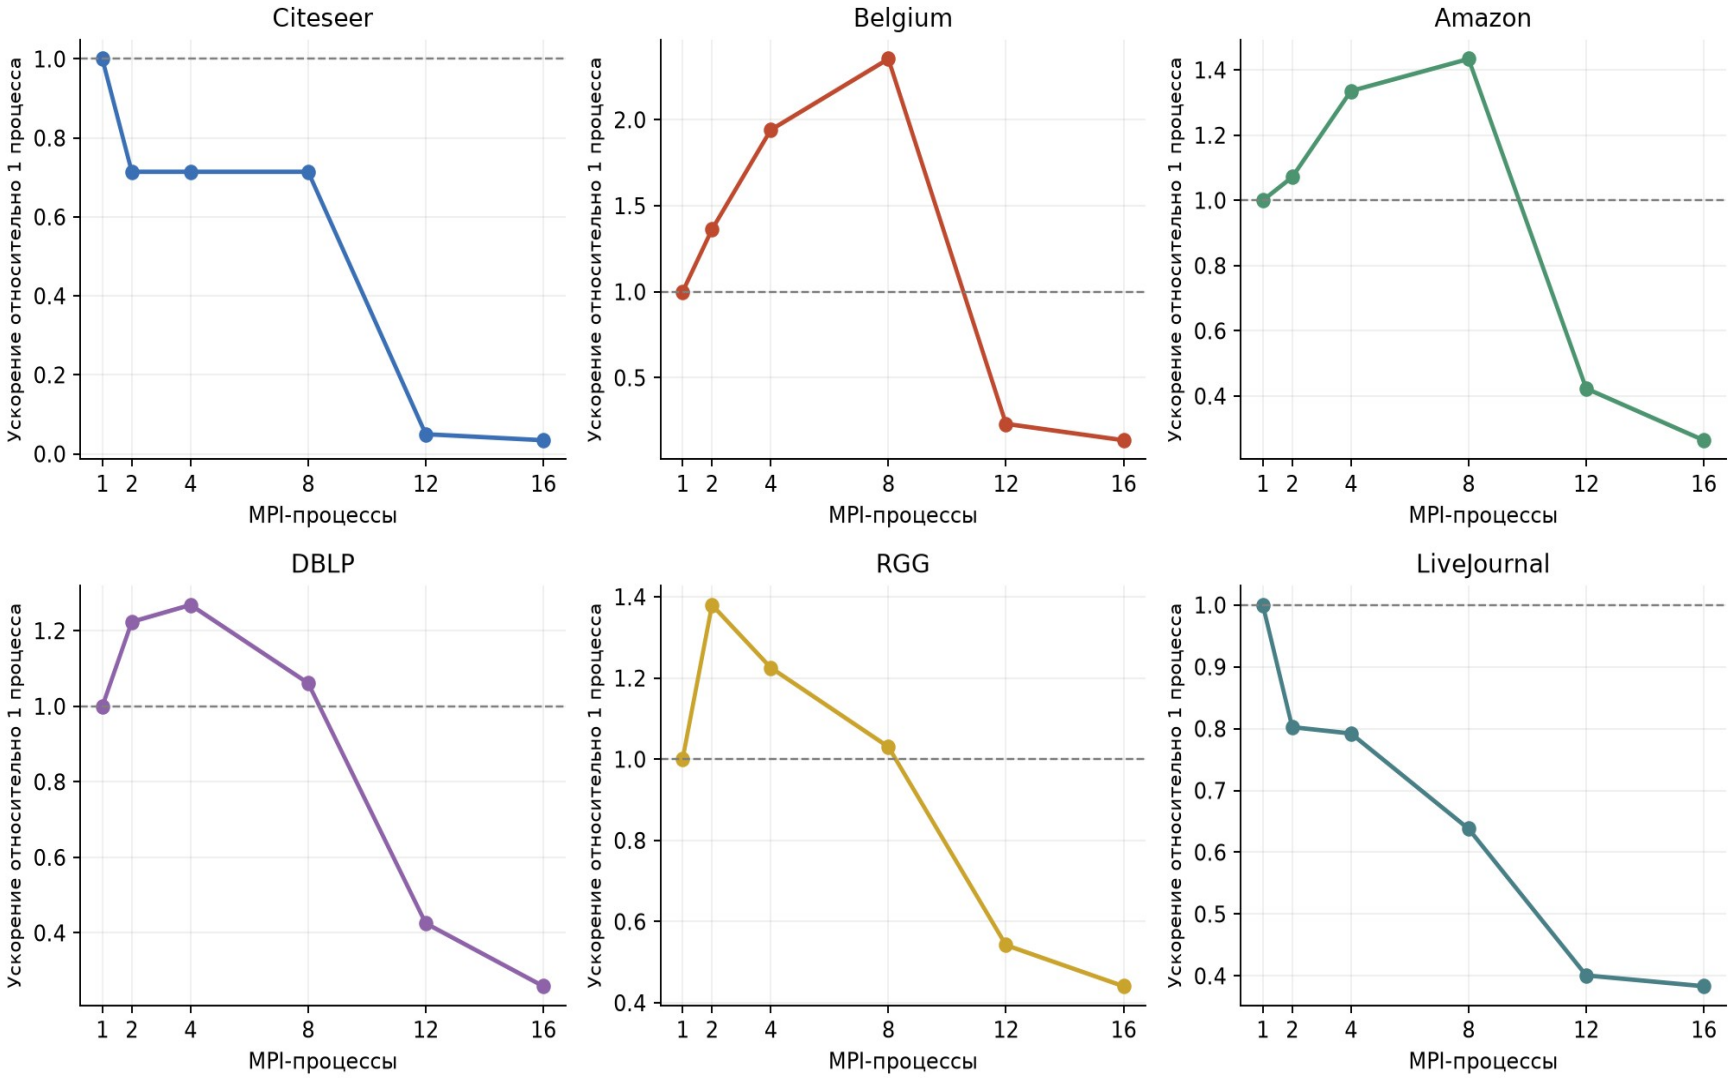
- BFS — bfs-push-dist.
- SSSP — sssp-push-dist, веса 1, -delta=0.
- TC — triangle-counting-dist, порядок по степеням.
- PageRank — pagerank-pull-dist, -tolerance=0.000001.

## Запуск и измерения

- mpirun -n P, P = 1, 2, 4, 8, 12, 16.
- -t=1: один рабочий поток на процесс.
- -symmetricGraph: неориентированный вход.
- -runs=21: 1 прогрев и 20 измерений.
- Основная метрика — медиана времени полного вызова.

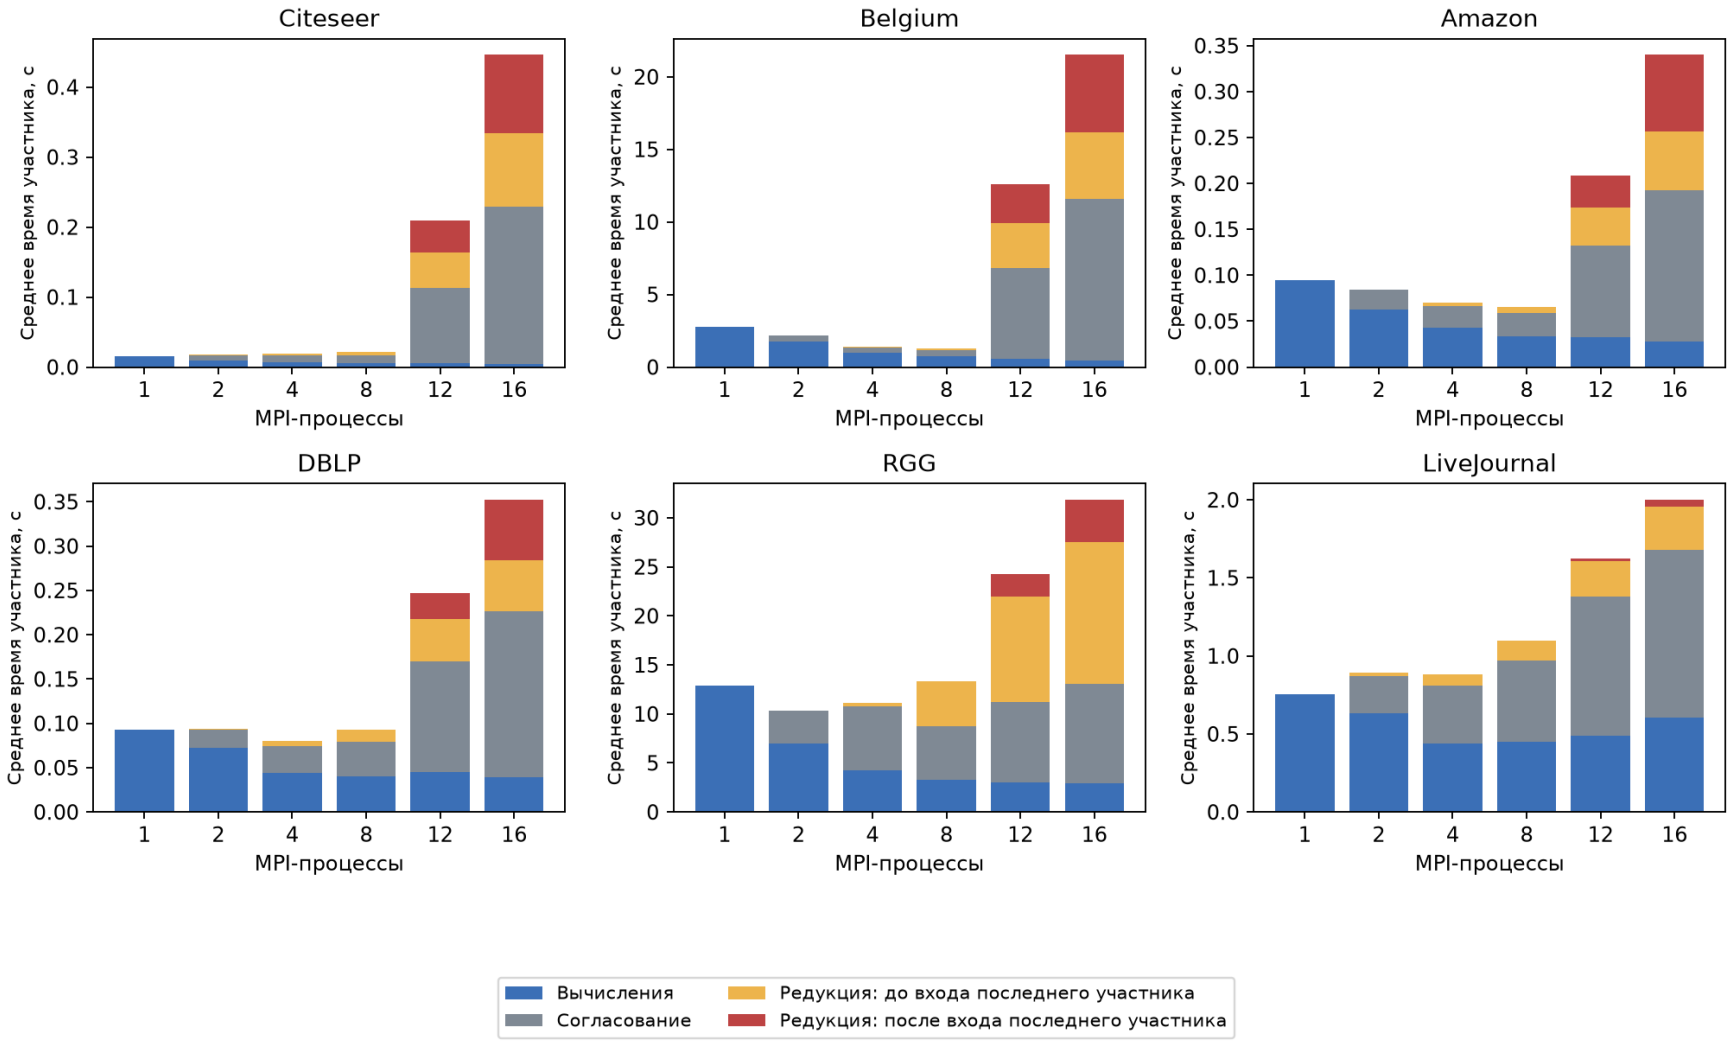
BFS, SSSP, PageRank: -partition=oec -exec=Sync -maxIterations=1000000.
TC: отдельный MiningGraph, без параметров -partition и -exec.
MPI: --use-hwthread-cpus --bind-to none, GALOIS_DO_NOT_BIND_THREADS=1.

# BFS: масштабирование



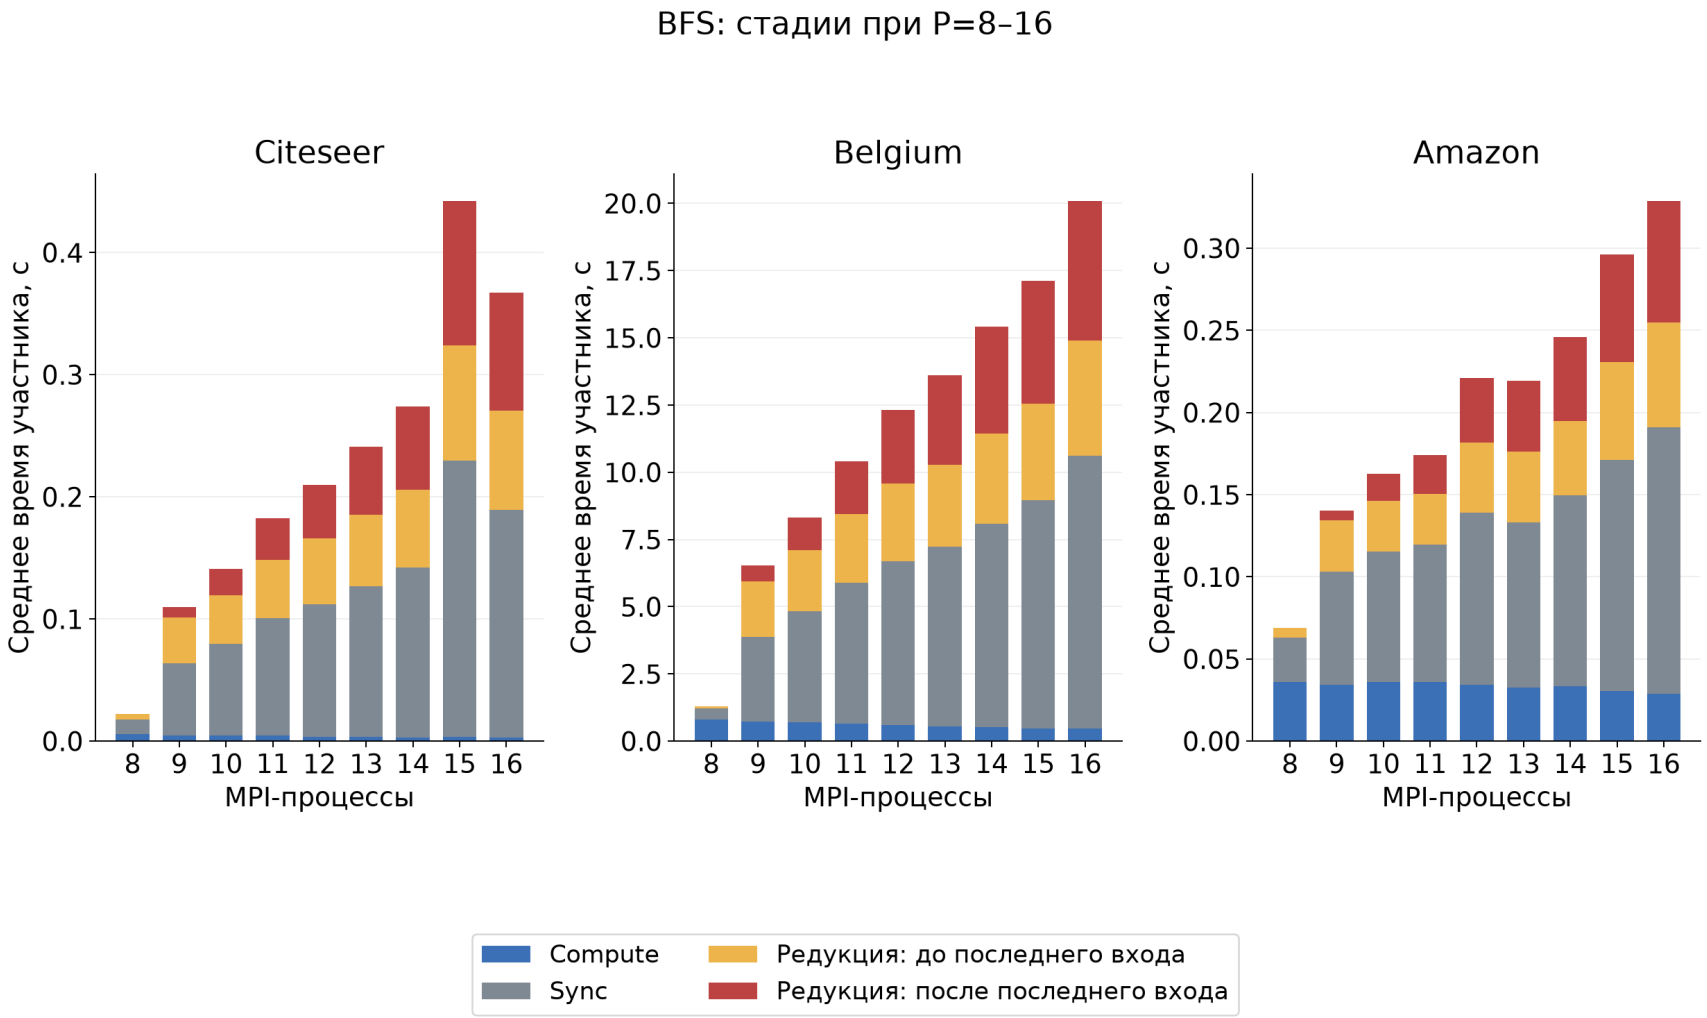

Лучшие конфигурации: P=1, 2, 4 или 8 — в зависимости от графа.

# BFS: куда уходит время участников




Вывод: выигрыш от разделения работы ограничивается ростом расходов взаимодействия.

# BFS: уточнение при P=8–16




Citeseer, Belgium, Amazon. P=8–16. Один прогрев и 10 диагностических измерений.

# BFS: куда ушло дополнительное время Sync

| Рабочий поток | P=8 мс | P=9 мс | Прирост мс | Доля прироста |
|---|---|---|---|---|
| Исполняется на CPU | 790,8 | 3055,5 | 2264,7 | 78,4% |
| Готов, но не получает CPU | 36,0 | 660,5 | 624,5 | 21,6% |
| Заблокирован, спит | 0,1 | 0,3 | 0,2 | <0,1% |
| Вся стадия Sync | 826,9 | 3716,3 | 2889,4 | 100,0% |

- На CPU — выполняет код, включая проверки очередей. Их время отдельно не выделено.
- Готов без CPU — может работать, но ждёт выделения CPU планировщиком.
- Заблокирован — ждёт пробуждения и не занимает CPU. Сон почти отсутствует.

Belgium. Среднее по процессам и двум диагностическим вызовам. Время накоплено за обход.

# BFS: переключения контекста в Compute и Sync

| Граф | Стадия | P=7 | P=8 | P=9 | P=10 |
|---|---|---|---|---|---|
| Citeseer | Compute | 0,03 | 0,80 | 0,91 | 0,64 |
| Citeseer | Sync | 0,17 | 1,25 | 6,36 | 9,02 |
| Belgium | Compute | 16,34 | 47,70 | 61,00 | 43,26 |
| Belgium | Sync | 7,91 | 41,62 | 428,49 | 569,84 |
| Amazon | Compute | 0,66 | 2,60 | 3,89 | 5,30 |
| Amazon | Sync | 0,74 | 1,77 | 5,93 | 11,00 |

- При P=8 → P=9 число переключений внутри Sync выросло на всех трёх графах.

Уходы рабочего потока с CPU за обход. Среднее по процессам и пяти измеренным вызовам.

# BFS: ожидание CPU по стадиям

| P | Compute | Sync | Проверка завершения |
|---|---|---|---|
| 1 | 0,3 (<0,1%) | 0,0 (0,0%) | 0,0 (0,0%) |
| 2 | 0,2 (<0,1%) | <0,1 (<0,1%) | <0,1 (<0,1%) |
| 4 | <0,1 (<0,1%) | <0,1 (<0,1%) | <0,1 (<0,1%) |
| 8 | 0,6 (0,6%) | 0,4 (0,5%) | <0,1 (0,3%) |
| 12 | 41,2 (32,7%) | 168,6 (37,6%) | 63,8 (35,0%) |
| 16 | 36,4 (41,7%) | 303,0 (52,6%) | 124,6 (47,5%) |

Медианы по 6 графам: мс ожидания CPU за вызов (доля времени стадии).
Медиана миллисекунд и медиана процентов рассчитаны отдельно.

# BFS: результаты и репликация данных

| Граф | Средняя степень | Лучшее P | Время, мс | Ускорение | RF вершин |
|---|---|---|---|---|---|
| Citeseer | 7,16 | 1 | 15,0 | 1,00× | 1,000 |
| Belgium | 2,15 | 8 | 1254,5 | 2,35× | 1,197 |
| Amazon | 9,58 | 8 | 68,0 | 1,43× | 2,293 |
| DBLP | 56,41 | 4 | 82,0 | 1,27× | 2,568 |
| RGG | 14,48 | 2 | 10116,5 | 1,38× | 1,002 |
| LiveJournal | 17,68 | 1 | 739,0 | 1,00× | 1,000 |

- Belgium: равномерная работа позволяет ускориться в 2,35 раза.
- RGG: малая репликация не исключает дисбаланс активной работы.
- Citeseer и LiveJournal: добавление процессов не окупается.

# BFS: выводы по графам (1/2)

- Citeseer: быстрее P=1, вызов занимает 15 мс. Малый объём работы не окупает согласования. При P=8→16 Sync растёт в 19,38×. При P=16 в Sync ожидание CPU — 107,4 мс за обход (52,4% времени стадии).
- Belgium: дорожный граф с малой степенью и длительным обходом, лучше P=8. Далее Compute сокращается на 39%, но сообщений становится в 4,31× больше, Sync растёт в 26,23×, редукция — в 127,57×.
- Amazon: лучше P=8. При дальнейшем делении Compute сокращается на 17%, но Sync растёт в 6,43×, редукция — в 24,05×. Экономию обработки перекрывает взаимодействие.

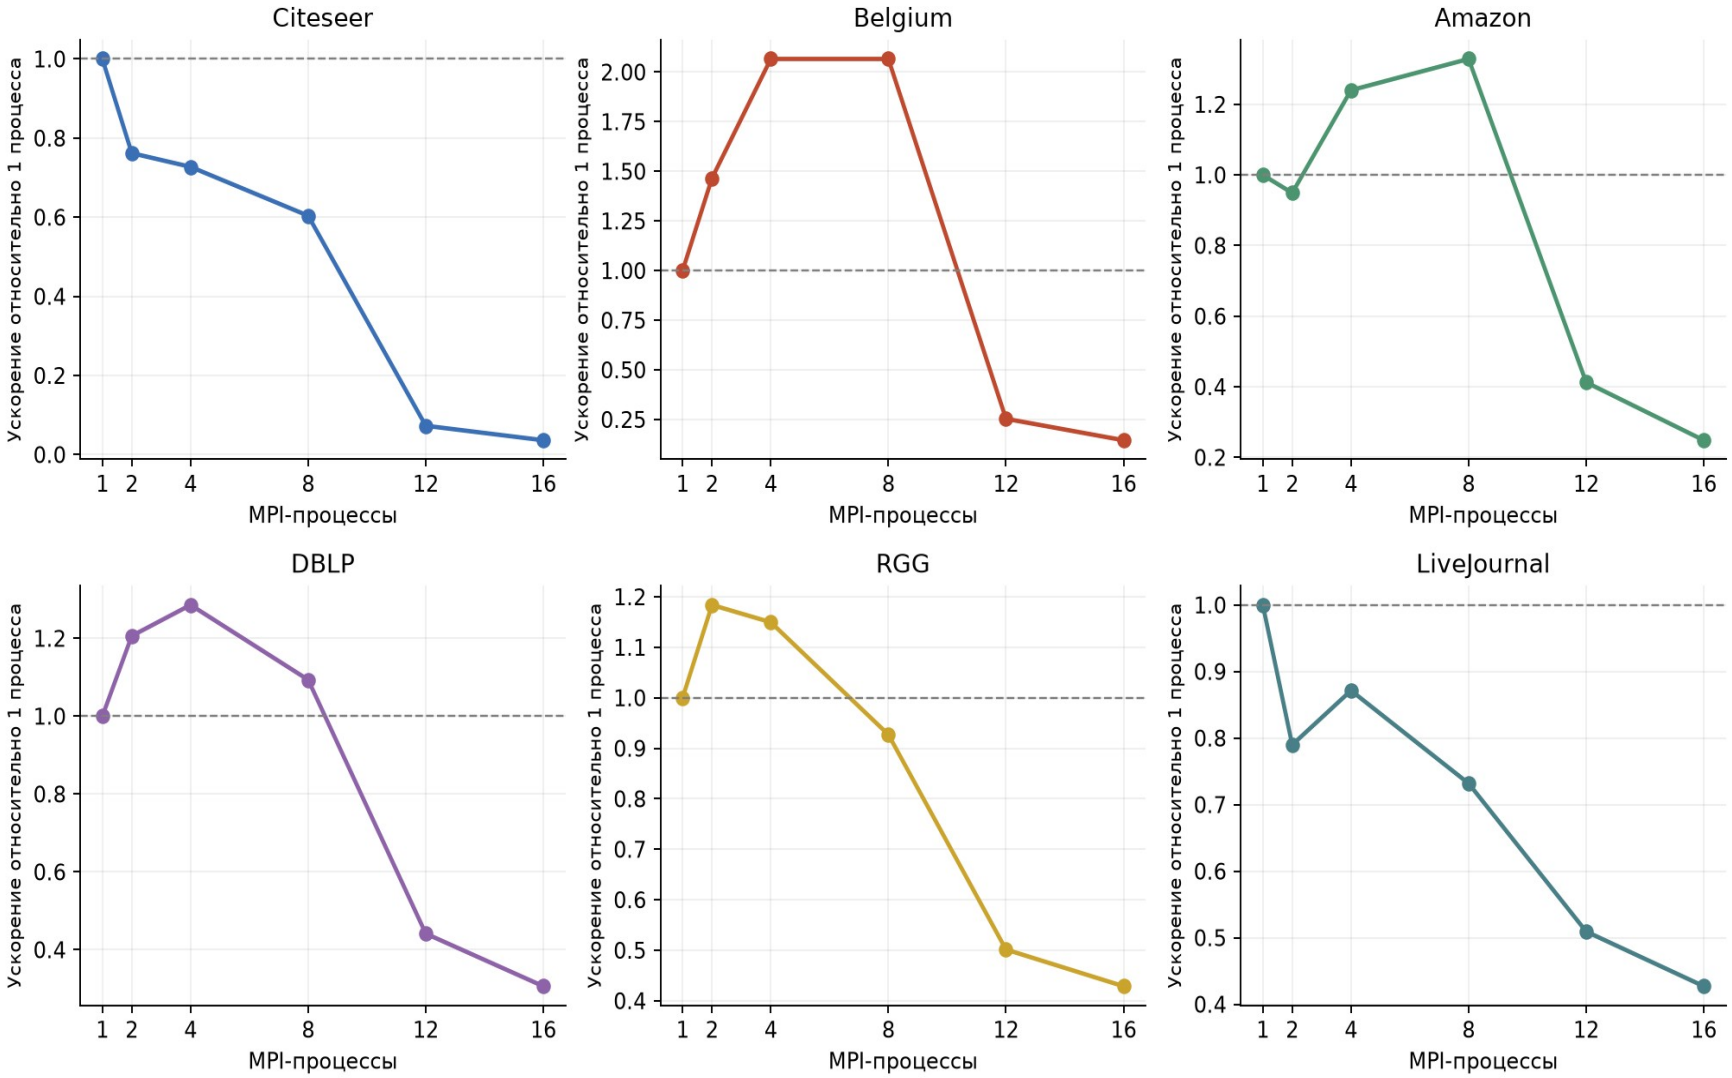
Коэффициенты — P=16 / P=8. Источники: отдельные диагностические серии.

# BFS: выводы по графам (2/2)

- DBLP: высокая средняя степень 56,41 не обеспечивает выигрыш от дальнейшего деления, лучше P=4. При P=8→16 Compute почти не меняется, Sync растёт в 4,72×. При P=16 в Sync ожидание CPU — 98,6 мс за обход (52,3% времени стадии).
- RGG: лучше P=2. Мало зеркальных копий, но активная работа распределена неравномерно: на P=8 максимальный объём в 2,91 раза больше среднего. При P=8→16 Sync растёт в 1,86×, редукция — в 4,08×.
- LiveJournal: лучше P=1. Разбиение добавляет повторные обработки и обмены. При P=8→16 средний Compute уже увеличивается на 35%, Sync растёт в 2,08×. Дальнейшее деление не ускоряет даже локальную стадию.

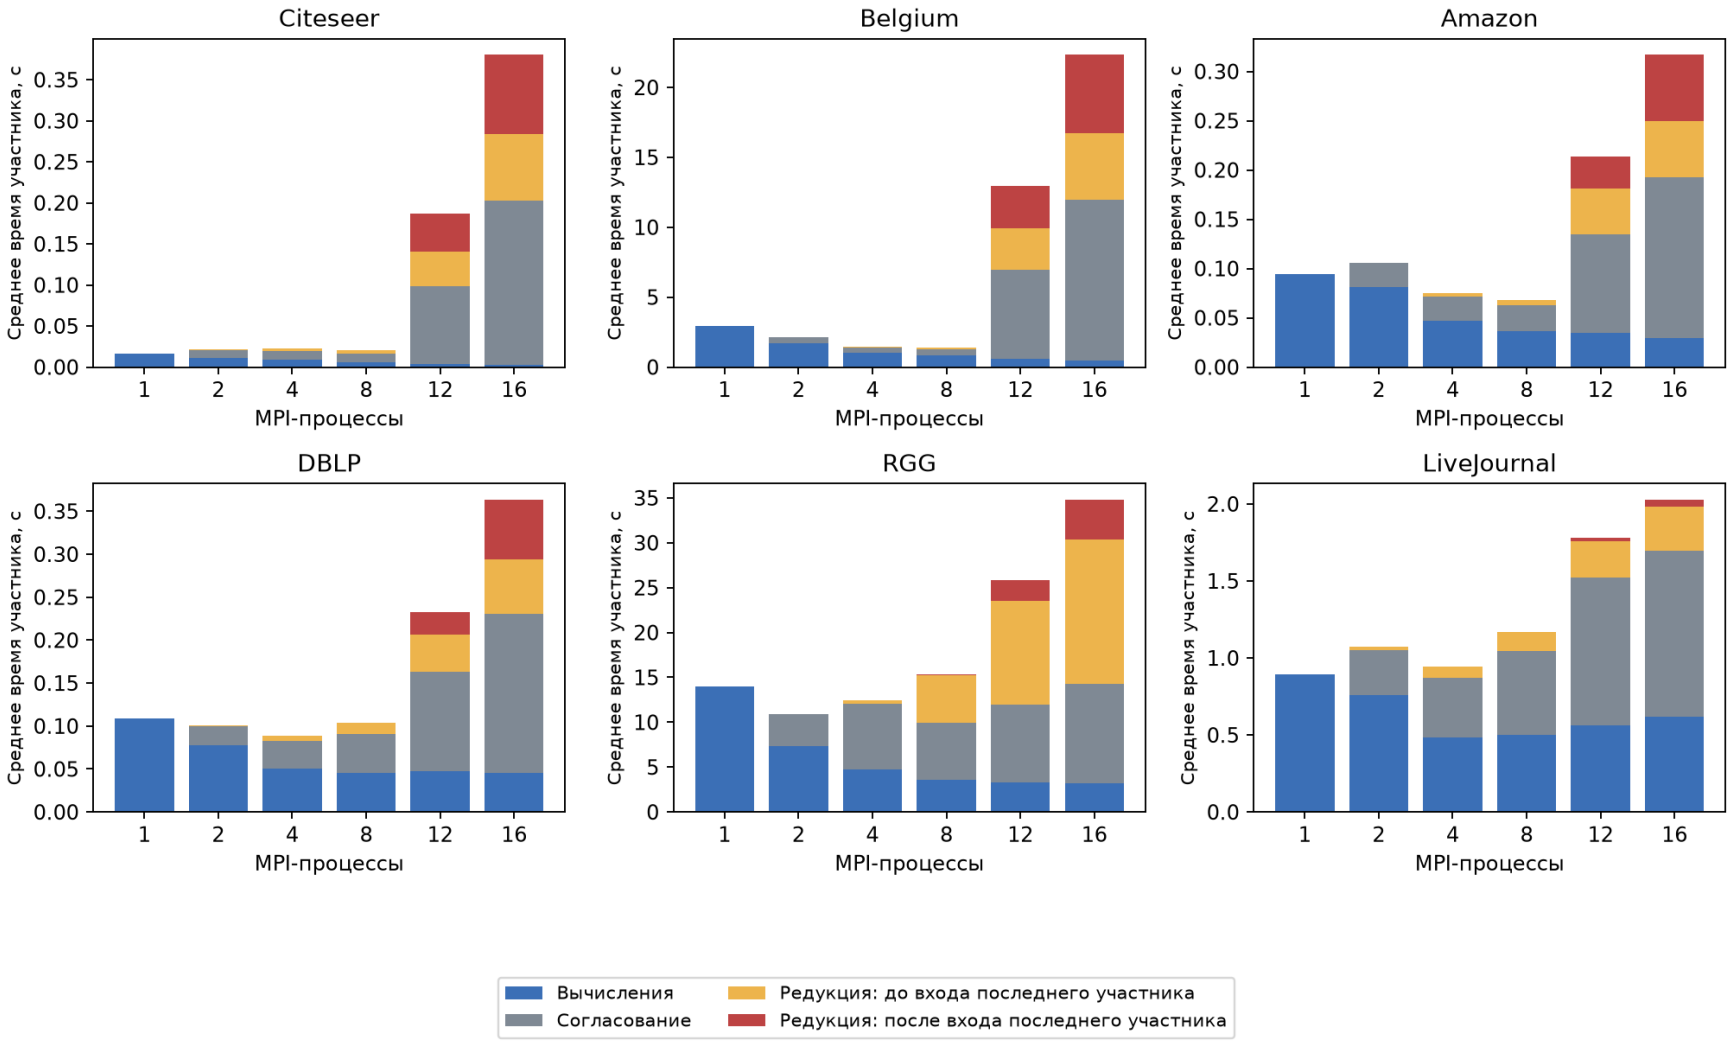
Коэффициенты — P=16 / P=8. Источники: отдельные диагностические серии.

# SSSP: масштабирование



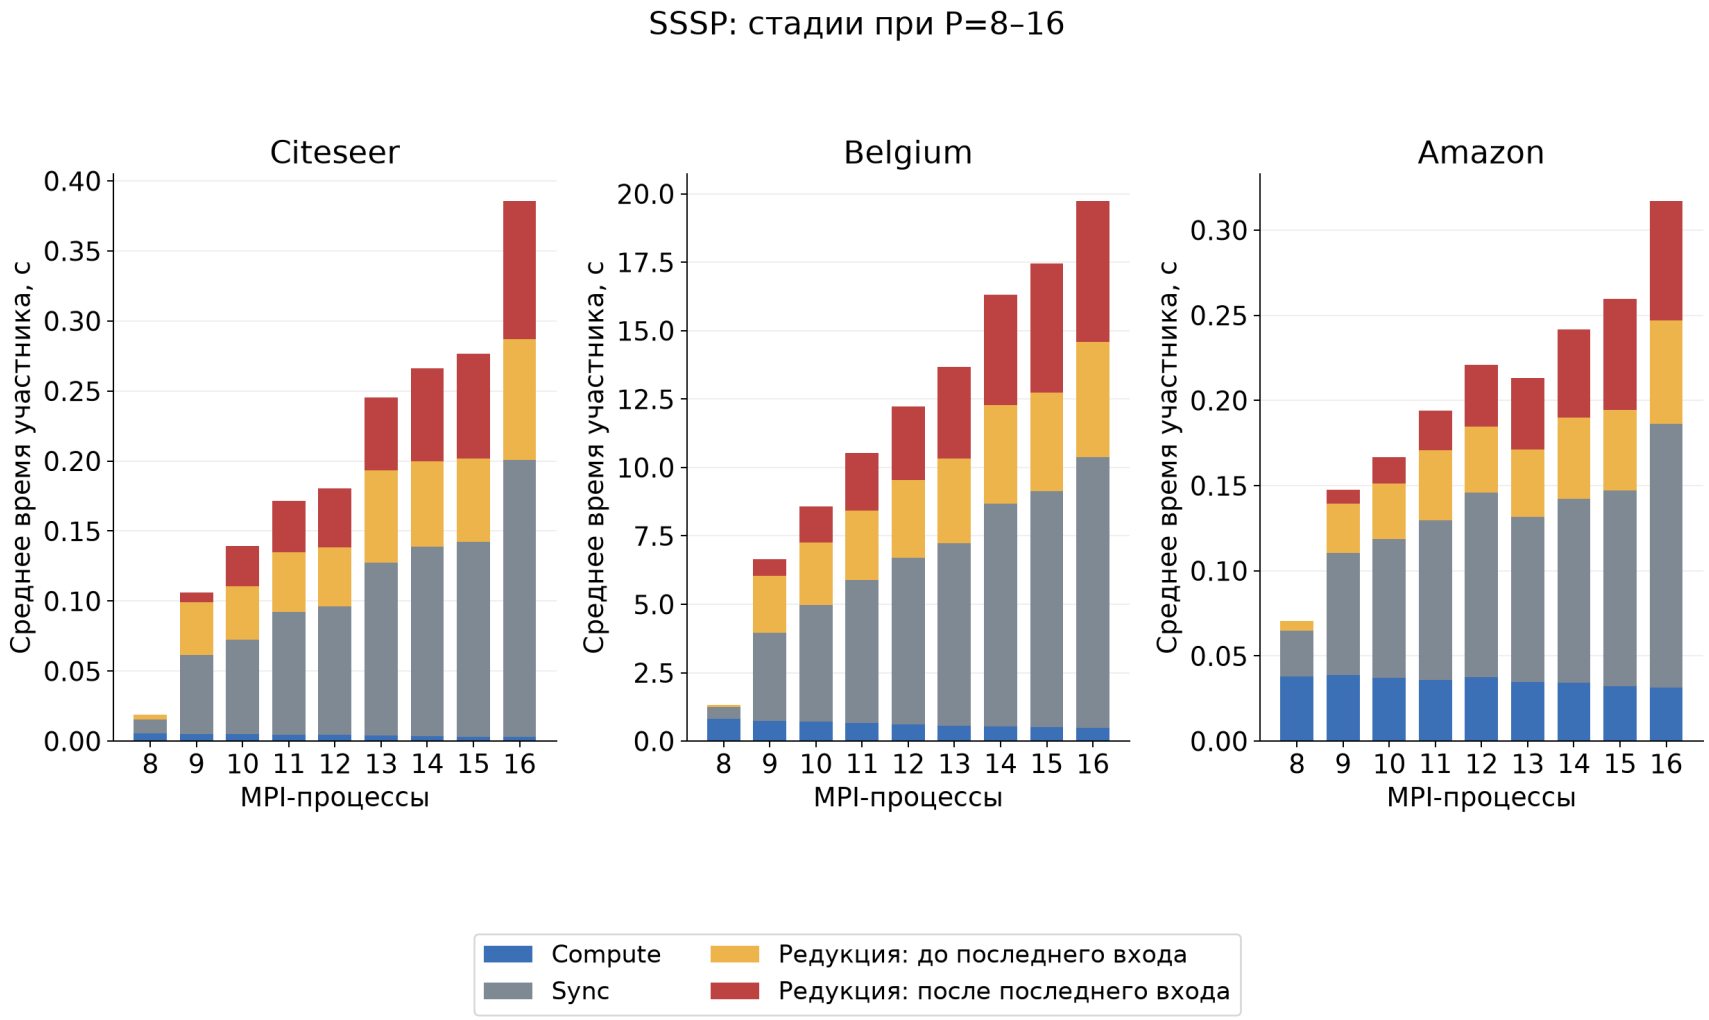

Лучшие точки совпадают с BFS, кроме Belgium: здесь быстрее P=4.

# SSSP: куда уходит время участников




Вывод: при единичных весах организация обменов ограничивает выигрыш, как у BFS.

# SSSP: уточнение при P=8–16




Citeseer, Belgium, Amazon. P=8–16. Один прогрев и 10 диагностических измерений.

# SSSP: ожидание CPU по стадиям

| P | Compute | Sync | Проверка завершения |
|---|---|---|---|
| 1 | 0,3 (<0,1%) | 0,0 (0,0%) | 0,0 (0,0%) |
| 2 | <0,1 (<0,1%) | <0,1 (<0,1%) | <0,1 (<0,1%) |
| 4 | <0,1 (<0,1%) | <0,1 (<0,1%) | <0,1 (<0,1%) |
| 8 | 0,7 (0,8%) | 0,6 (0,8%) | 0,1 (0,5%) |
| 12 | 52,0 (32,9%) | 183,8 (37,5%) | 61,2 (35,3%) |
| 16 | 45,1 (42,8%) | 359,6 (52,4%) | 143,5 (47,1%) |

Медианы по 6 графам: мс ожидания CPU за вызов (доля времени стадии).
Медиана миллисекунд и медиана процентов рассчитаны отдельно.

# SSSP: результаты и репликация данных

| Граф | Средняя степень | Лучшее P | Время, мс | Ускорение | RF вершин |
|---|---|---|---|---|---|
| Citeseer | 7,16 | 1 | 16,0 | 1,00× | 1,000 |
| Belgium | 2,15 | 4 | 1558,5 | 2,07× | 1,159 |
| Amazon | 9,58 | 8 | 70,0 | 1,33× | 2,293 |
| DBLP | 56,41 | 4 | 91,0 | 1,29× | 2,568 |
| RGG | 14,48 | 2 | 11928,5 | 1,18× | 1,002 |
| LiveJournal | 17,68 | 1 | 877,5 | 1,00× | 1,000 |

- Belgium: лучшее P=4, Amazon: P=8. Единого оптимума нет.
- При единичных весах распределение активной работы близко к BFS.
- Для коротких вызовов и частых согласований выигрыш ограничен.

# SSSP: выводы по графам (1/2)

- Citeseer: быстрее P=1, 16 мс. На коротком обходе дополнительные процессы не окупаются. При P=8→16 Compute сокращается на 52%, но Sync растёт в 19,01×, редукция — в 46,98×.
- Belgium: лучше P=4. Длительный обход повторяет обмены почти тысячу раз. При P=8→16 Compute сокращается на 41%, но Sync растёт в 24,26×, редукция — в 108,77×.
- Amazon: лучше P=8. Далее Compute сокращается на 21%, а сообщений становится в 4,29× больше. Sync растёт в 6,34×, редукция — в 20,94×. Взаимодействие перекрывает выигрыш вычислений.

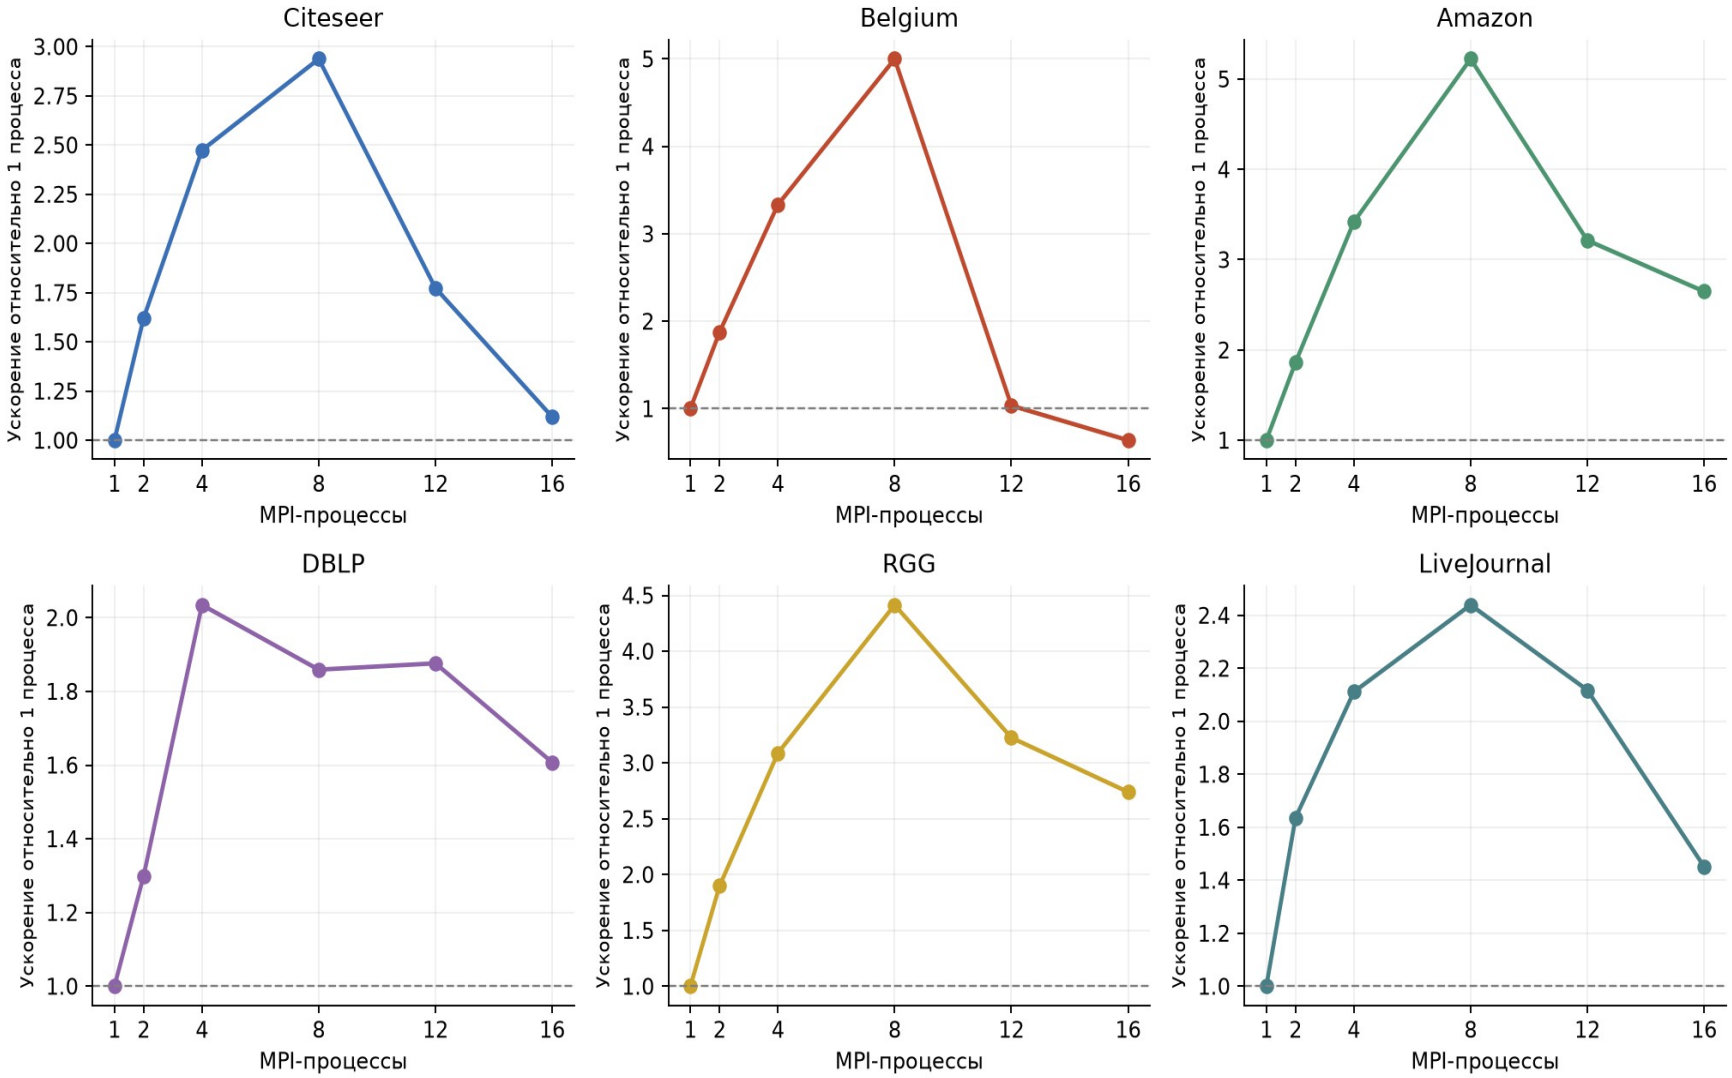
Коэффициенты — P=16 / P=8. Источники: отдельные диагностические серии.

# SSSP: выводы по графам (2/2)

- DBLP: лучше P=4. При P=8→16 Compute почти не меняется, но Sync растёт в 4,13×. Высокая степень не гарантирует полезного дальнейшего деления. При P=16 в Sync ожидание CPU — 100,3 мс за обход (51,9% времени стадии).
- RGG: лучше P=2. Геометрическая локальность уменьшает репликацию, но не гарантирует равномерную активную работу. При P=8→16 Compute сокращается на 10%, редукция растёт в 3,80×, основная её часть проходит до последнего входа.
- LiveJournal: лучше P=1. На P=8 больше обработок рёбер, чем на одном процессе. При P=8→16 Compute увеличивается на 23%, Sync — в 1,98×, редукция — в 2,67×. Издержки растут вместе с локальной обработкой.

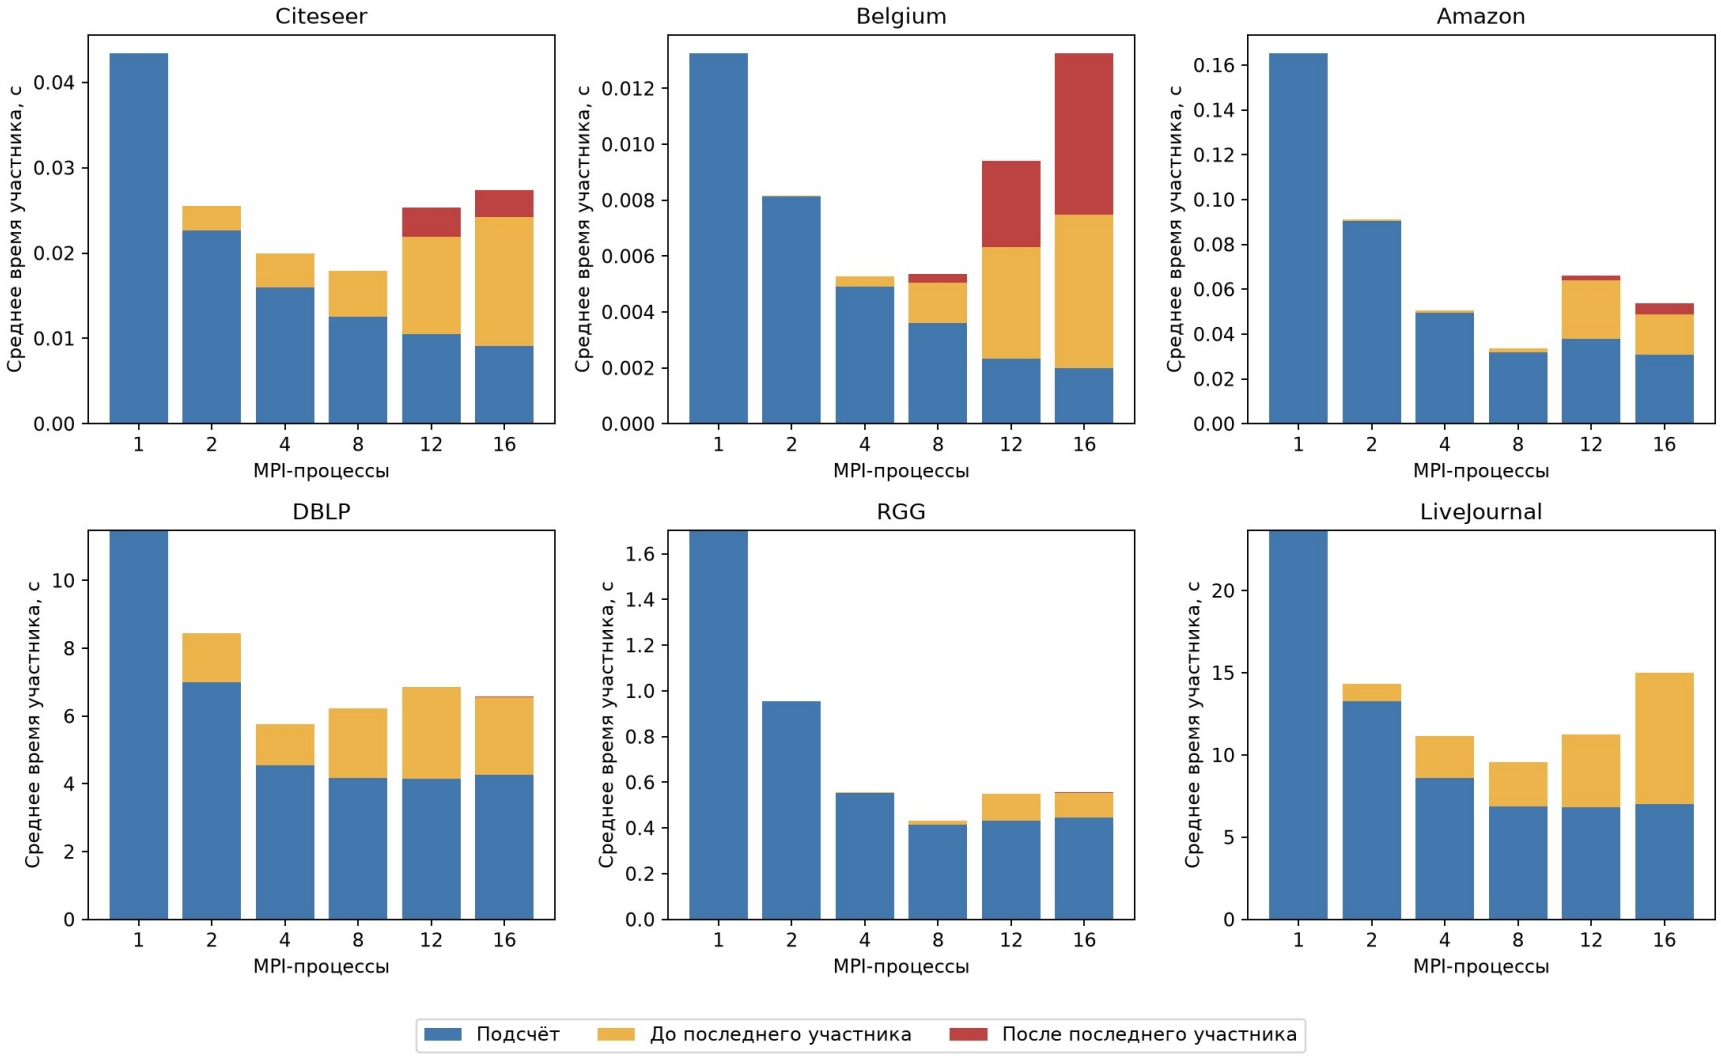
Коэффициенты — P=16 / P=8. Источники: отдельные диагностические серии.

# Triangle Count: масштабирование



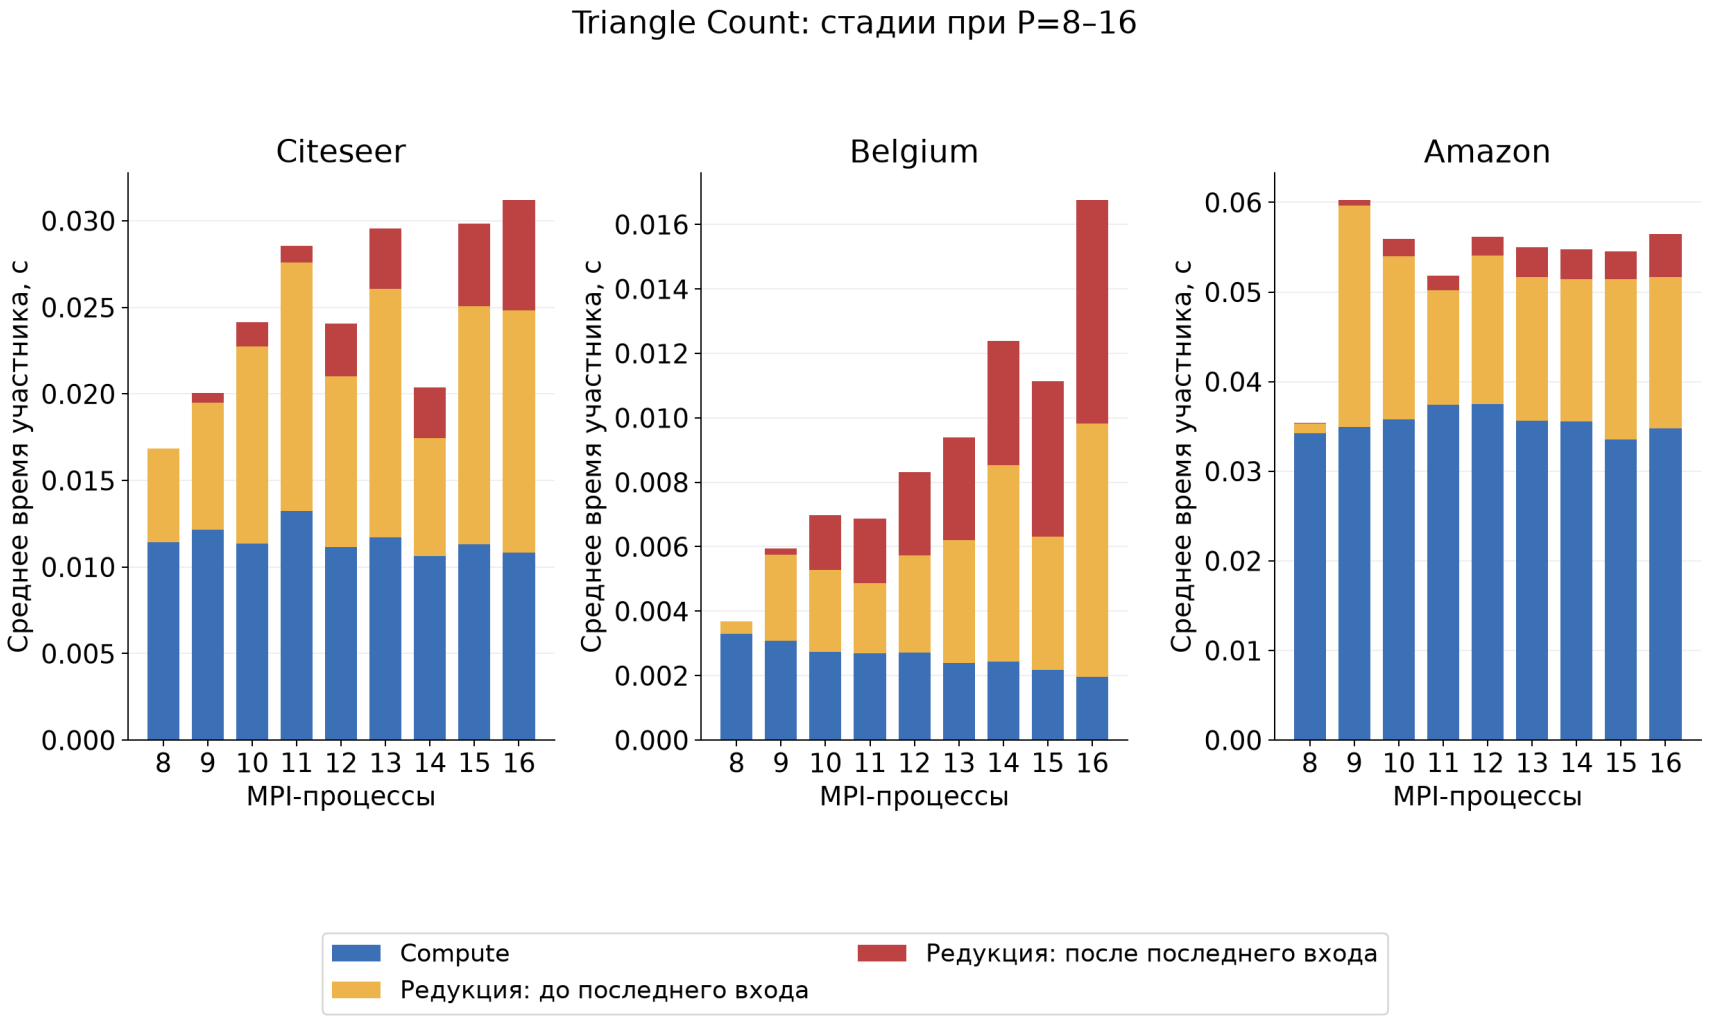

Лучшее P: DBLP — 4, остальные пять графов — 8.

# Triangle Count: подсчёт и ожидание участников




Редукция разделена на время до входа последнего участника и после него.

# Triangle Count: уточнение при P=8–16




Citeseer, Belgium, Amazon. P=8–16. Один прогрев и 10 диагностических измерений.

# Triangle Count: ожидание CPU по стадиям

| P | Compute | Финальная редукция |
|---|---|---|
| 1 | 0,2 (<0,1%) | 0,0 (0,0%) |
| 2 | 0,2 (<0,1%) | 0,0 (0,0%) |
| 4 | 0,1 (<0,1%) | 0,0 (0,0%) |
| 8 | 2,5 (0,7%) | 0,1 (1,0%) |
| 12 | 100,8 (36,8%) | 23,2 (33,4%) |
| 16 | 134,4 (51,4%) | 34,2 (47,7%) |

Медианы по 6 графам: мс ожидания CPU за вызов (доля времени стадии).
Медиана миллисекунд и медиана процентов рассчитаны отдельно.

# TC: результаты и репликация данных

| Граф | Средняя степень | Лучшее P | Время, мс | Ускорение | RF вершин | RF рёбер |
|---|---|---|---|---|---|---|
| Citeseer | 7,16 | 8 | 16,0 | 2,94× | 1,480 | 1,425 |
| Belgium | 2,15 | 8 | 3,0 | 5,00× | 1,094 | 1,011 |
| Amazon | 9,58 | 8 | 36,0 | 5,22× | 1,628 | 1,295 |
| DBLP | 56,41 | 4 | 6093,5 | 2,03× | 1,599 | 1,682 |
| RGG | 14,48 | 8 | 426,0 | 4,41× | 1,005 | 1,003 |
| LiveJournal | 17,68 | 8 | 10183,0 | 2,44× | 2,102 | 3,480 |

- RGG: почти нет дополнительных копий, ускорение 4,41×.
- LiveJournal: копий рёбер больше в 3,48 раза, ускорение 2,44×.
- Репликация характеризует хранение данных, но сама не определяет ускорение.

# Triangle Count: выводы по графам (1/2)

- Citeseer: лучше P=8. При переходе к шестнадцати процессам Compute сокращается на 27%, но редукция растёт в 3,36×. На коротком подсчёте завершающие расходы перекрывают экономию.
- Belgium: лучше P=8. Compute сокращается на 45%, редукция растёт в 6,37×. В sched-трассе на P=16 после последнего входа 3,48 из 6,19 мс приходится на готовность потока без получения CPU.
- Amazon: лучше P=8, ускорение 5,22×. Далее Compute почти не сокращается, редукция растёт в 11,64×. При P=16 в редукции ожидание CPU — 11,3 мс за вызов (46,7% времени стадии).

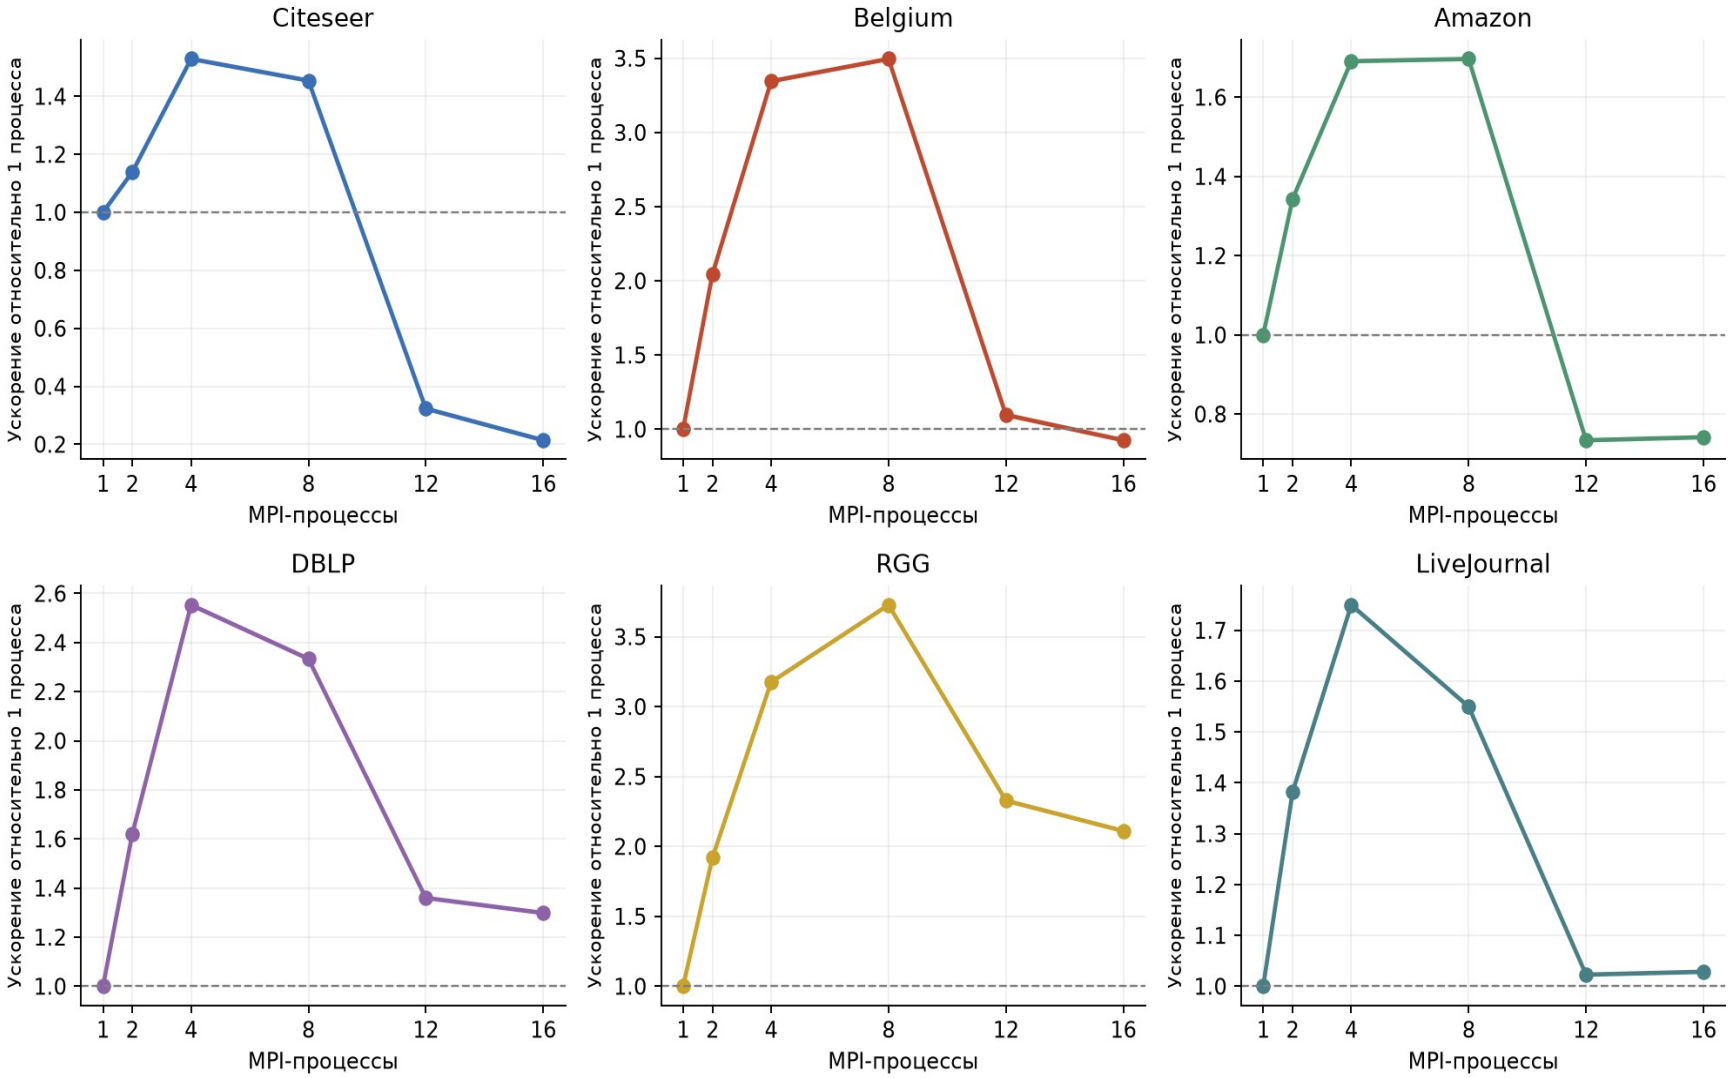
Коэффициенты — P=16 / P=8. Источники: отдельные диагностические серии.

# Triangle Count: выводы по графам (2/2)

- DBLP: лучше P=4. Списки соседей создают неравномерное время завершения. На P=8 средняя редукция 2037,64 мс, из них 2037,61 мс проходит до входа последнего участника. Большое время не означает дорогую арифметическую сумму.
- RGG: лучше P=8. Почти нет дополнительных копий, но далее Compute увеличивается на 8%, редукция — в 6,19×. На P=16 около 97% редукции проходит до входа последнего участника.
- LiveJournal: лучше P=8. При переходе к P=16 средний Compute почти не меняется: 6,87→7,01 с, но самый медленный участник считает 9,56→15,01 с. Среднее время в редукции до его прихода растёт с 2,69 до 7,99 с.

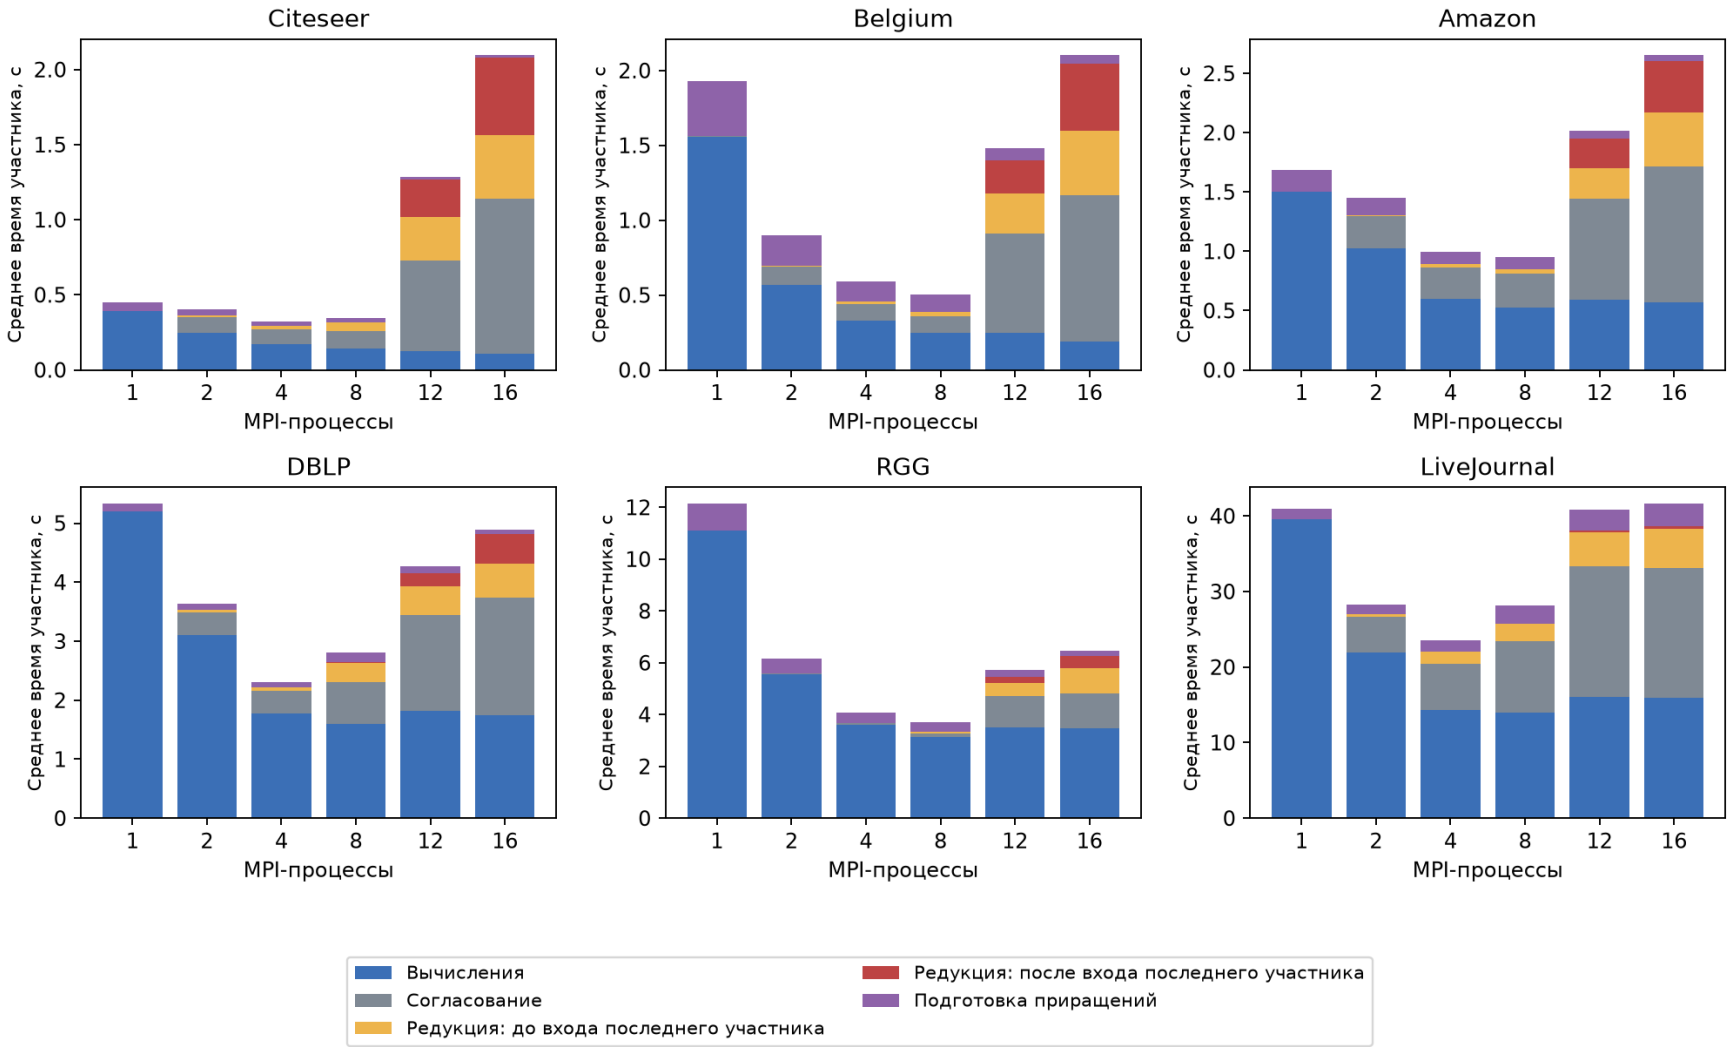
Коэффициенты — P=16 / P=8. Источники: отдельные диагностические серии.

# PageRank: масштабирование



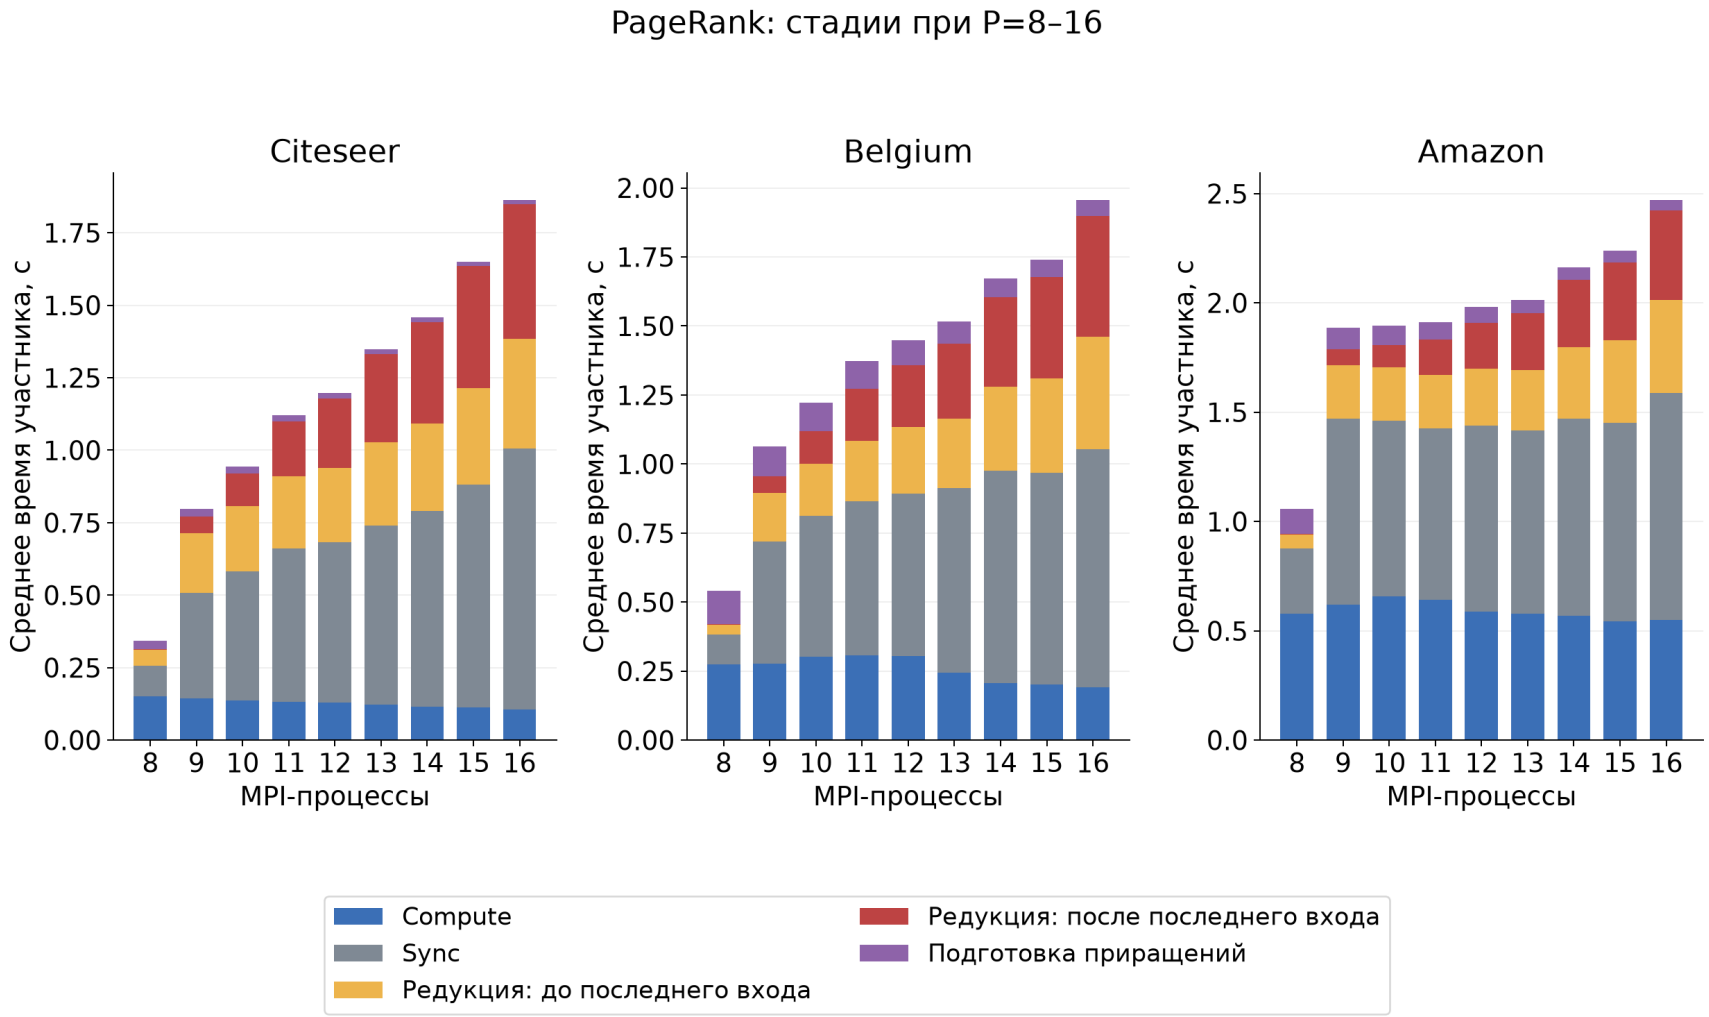

Все шесть графов ускоряются, лучшие точки — P=4 или P=8.

# PageRank: вычисления и завершение раундов




Вывод: крупная работа между обменами позволяет лучше окупать взаимодействие.

# PageRank: уточнение при P=8–16




Citeseer, Belgium, Amazon. P=8–16. Один прогрев и 10 диагностических измерений.

# PageRank: ожидание CPU по стадиям

| P | Подготовка приращений | Compute | Sync | Проверка завершения |
|---|---|---|---|---|
| 1 | <0,1 (<0,1%) | 1,0 (<0,1%) | 0,0 (0,0%) | 0,0 (0,0%) |
| 2 | <0,1 (<0,1%) | 0,4 (<0,1%) | <0,1 (<0,1%) | <0,1 (<0,1%) |
| 4 | <0,1 (<0,1%) | 0,2 (<0,1%) | <0,1 (<0,1%) | <0,1 (<0,1%) |
| 8 | 1,4 (0,8%) | 14,3 (1,0%) | 1,2 (0,7%) | 0,5 (0,3%) |
| 12 | 19,2 (18,4%) | 508,9 (40,3%) | 295,1 (33,7%) | 211,0 (34,8%) |
| 16 | 5,6 (7,7%) | 603,6 (51,2%) | 638,5 (52,7%) | 480,5 (48,1%) |

Медианы по 6 графам: мс ожидания CPU за вызов (доля времени стадии).
Медиана миллисекунд и медиана процентов рассчитаны отдельно.

# PageRank: результаты и репликация данных

| Граф | Средняя степень | Лучшее P | Время, мс | Ускорение | RF вершин |
|---|---|---|---|---|---|
| Citeseer | 7,16 | 4 | 302,5 | 1,53× | 2,080 |
| Belgium | 2,15 | 8 | 557,0 | 3,50× | 1,197 |
| Amazon | 9,58 | 8 | 1049,5 | 1,70× | 2,293 |
| DBLP | 56,41 | 4 | 2417,5 | 2,55× | 2,568 |
| RGG | 14,48 | 8 | 3503,5 | 3,73× | 1,007 |
| LiveJournal | 17,68 | 4 | 22824,0 | 1,75× | 2,653 |

- Все шесть графов ускоряются, лучшие конфигурации — P=4 или P=8.
- RGG: почти нет дополнительных копий, ускорение 3,73 раза.
- LiveJournal: больше репликация и объём обменов, ускорение 1,75 раза.

# PageRank: выводы по графам (1/2)

- Citeseer: лучше P=4. Повторяющаяся обработка даёт выигрыш даже на небольшом графе. При P=8→16 Compute сокращается на 25%, но Sync растёт в 8,73×, редукция — в 16,40×.
- Belgium: лучше P=8, низкая степень не мешает ускорению повторяющейся обработки. Далее объём отправок растёт лишь в 1,15×, но Sync — в 9,13×. Одним увеличением байтов рост времени не объясняется.
- Amazon: лучше P=8. При переходе к шестнадцати процессам Compute увеличивается на 8%, Sync — в 4,04×, редукция — в 22,76×. Дополнительные процессы уже не ускоряют обработку.

Коэффициенты — P=16 / P=8. Источники: отдельные диагностические серии.

# PageRank: выводы по графам (2/2)

- DBLP: лучше P=4, большой объём соседств даёт полезную работу. При P=8→16 Compute увеличивается на 9%, Sync — в 2,83×. При P=16 в Sync ожидание CPU — 985,5 мс за вызов (52,0% времени стадии).
- RGG: лучше P=8, репликация близка к единице, ускорение 3,73×. При дальнейшем делении Compute увеличивается на 10%, Sync растёт в 11,09×. Малая репликация не устраняет задержки исполнения и коллективных операций.
- LiveJournal: лучше P=4. На P=8→16 логические отправки растут с 4,04 до 5,87 ГБ, Sync — в 1,81×. Средний Compute увеличивается на 14%. Большой граф не гарантирует масштабирование. При P=16 в Sync ожидание CPU — 8133,2 мс за вызов (47,9% времени стадии).

Коэффициенты — P=16 / P=8. Источники: отдельные диагностические серии.

# Сводка лучших измеренных конфигураций

| Граф | BFS<br>P* / S | SSSP<br>P* / S | PageRank<br>P* / S | Triangle Count<br>P* / S |
|---|---|---|---|---|
| Citeseer | 1 / 1,00× | 1 / 1,00× | 4 / 1,53× | 8 / 2,94× |
| Belgium | 8 / 2,35× | 4 / 2,07× | 8 / 3,50× | 8 / 5,00× |
| Amazon | 8 / 1,43× | 8 / 1,33× | 8 / 1,70× | 8 / 5,22× |
| DBLP | 4 / 1,27× | 4 / 1,29× | 4 / 2,55× | 4 / 2,03× |
| RGG | 2 / 1,38× | 2 / 1,18× | 8 / 3,73× | 8 / 4,41× |
| LiveJournal | 1 / 1,00× | 1 / 1,00× | 4 / 1,75× | 8 / 2,44× |

P* — число процессов с минимальной медианой, S = T(1) / T(P*).

# Выводы

- Разделение графа ускоряет вычисления до своего предела. На нашей машине лучшие конфигурации — P=1–8, в зависимости от графа и алгоритма.
- При P=8→16 у BFS, SSSP и PageRank сообщений типично больше в 4,29 раза, а Sync длительнее в 5,23–6,39 раза. Рост взаимодействий перекрывает экономию локальной работы.
- Внутри согласований рабочие потоки готовы, но не получают CPU. Доля измерена отдельно для каждой стадии. Большая редукция включает ожидание поздних участников и задержки завершения MPI.
- Структура графа задаёт объём работы, связи между частями и равномерность загрузки. Эти свойства вместе с доступными ресурсами определяют полезное число процессов.